

问题一模型分析报告

1. 数据与建模设置

本次建模使用 2025 年全年数据作为训练集，目标变量为出水浊度 NTU。验证集使用 2026 年 1 月；
训练数据在建模前构造了 2、4、6 小时时滞变量，涉及变量为：

变量	时滞
R/W NTU	2h, 4h, 6h
FILT. NTU	2h, 4h, 6h
ALUM	2h, 4h, 6h

最终样本量如下：

数据集	时间范围	样本量
训练集	2025-01-01 07:00 到 2025-12-31 23:00	4377
验证集	2026-01-01 07:00 到 2026-01-31 23:00	357

2. 模型结果

本次比较了随机森林、XGBoost 和两者简单平均集成模型。评价指标包括 MAE、RMSE 和 R2。

模型	数据集	MAE	RMSE	R2
随机森林	训练集	0.1313	0.1997	0.8534
随机森林	验证集	0.1439	0.1677	0.3649
XGBoost	训练集	0.1244	0.1849	0.8743
XGBoost	验证集	0.1468	0.1809	0.2612
平均集成	训练集	0.1270	0.1892	0.8684
平均集成	验证集	0.1443	0.1724	0.3292

从验证集表现看，随机森林单模型的 MAE、RMSE 和 R2 仍然最优。平均集成模型的 MAE 与随机森林接近，但 RMSE 和 R2 略弱于随机森林。XGBoost 单模型相较随机森林泛化效果稍弱。

平均集成模型相较 XGBoost 有改善，但没有超过随机森林单模型。因此，在当前特征和参数设置下，若以 2026 年 1 月验证集为准，随机森林是更优选择。

3. 关键变量分析

XGBoost 特征重要性排名靠前的变量如下：

排名	特征	重要性
1	FILT. NTU_LAG_2H	0.3359
2	FILT. NTU	0.3251
3	R/W FLOW	0.0699
4	FILT. NTU_LAG_4H	0.0589
5	R/W NTU	0.0378
6	RIVER LEVEL	0.0367
7	FILT. NTU_LAG_6H	0.0228
8	ALUM	0.0221
9	R/W NTU_LAG_2H	0.0206
10	R/W NTU_LAG_6H	0.0144

结果表明，FILT. NTU 及其短时滞后项是预测出水 NTU 的核心变量。这符合工艺逻辑：过滤后浊度与最终出水浊度最直接相关。R/W FLOW、R/W NTU 和河流水位也提供了原水状态与运行负荷信息。

4. 2026 年 2 月指定日期预测

以下结果为随机森林和 XGBoost 的简单平均集成预测。

日期	日均预测 NTU	最小预测 NTU	最大预测 NTU
2026-02-01	0.3703	0.3599	0.3903
2026-02-10	0.4328	0.3972	0.4721
2026-02-20	0.3683	0.3495	0.3805

逐时预测结果已保存至：

Question1/outputs/xgboost_ensemble/feb_1_10_20_predictions.csv

从预测结果看，2 月 10 日整体预测值最高，日均预测 NTU 为 0.4328；2 月 20 日与 2 月 1 日较接近，日均预测 NTU 分别为 0.3683 和 0.3703。三个日期的预测值均处于较低浊度区间，没有出现明显异常高值。

5. 结论

1. 在当前验证方式下，随机森林模型验证集表现最好，验证集 MAE 为 0.1439，RMSE 为 0.1677，R2 为 0.3649。

2. XGBoost 在训练集上拟合能力较强，但验证集效果弱于随机森林，说明存在一定过拟合或跨期泛化不足。
3. 平均集成模型提高了 XGBoost 的稳定性，但未超过随机森林单模型。
4. 影响出水浊度的关键变量主要是 `FILT. NTU_LAG_2H`、`FILT. NTU`、`R/W FLOW`、`R/W NTU` 相关变量。
5. 对 2026 年 2 月 1 日、10 日、20 日的预测显示，2 月 10 日出水浊度水平相对更高。