

问题 1：出厂水浊度 (NTU) 多元线性回归模型

1 变量含义

数据来自某自来水厂连续 15 个月（2025 年 1 月–12 月）的运行监测记录，每天 12 条（每 2 小时一条，时间编码 100 代表 00:00，300 代表 03:00，以此类推至 2300）。目标变量为出厂水浊度 NTU。

表 1: 候选自变量及其工艺含义

变量	全称	中文含义	单位	工艺位置
NTU	Treated Water Turbidity	出厂水浊度（目标）	NTU	清水池出水
FILT. NTU	Filtered Water Turbidity	滤后水浊度	NTU	过滤后
R/W NTU	Raw Water Turbidity	原水浊度	NTU	进水端
R/W FLOW	Raw Water Flow Rate	原水流量	–	进水端
R/W CLR	Raw Water Color	原水色度	–	进水端
ALUM	Alum Dosage	矾投加量	mg/L	混凝环节
R/W PH	Raw Water pH	原水 pH 值	–	进水端

2 变量筛选

2.1 物理因果初筛

水处理工艺流程为：原水 → 混凝 (加矾) → 沉淀 → 过滤 → 清水池 (加氯) → 送水。仅选取上游工艺变量作为候选自变量，排除以下变量：

- 下游结果变量（因果倒置）：清水池 PH、CLR、余氯 CL2、送水流量 T/W FLOW
- 冗余变量（信息被其他变量覆盖）：RIVER LEVEL（已由 R/W NTU 表征）、R/W PUMP DUTY 和 T/W PUMP DUTY（已由 R/W FLOW 体现）
- 数据不可用：F/RIDE（与 ALUM 重复且 83% 缺失）、18ML LEVEL/FLOW（几乎全缺）、REMARKS（非定量）

初选 6 个候选变量：R/W NTU、FILT. NTU、R/W FLOW、R/W CLR、ALUM、R/W PH。

2.2 缺失处理策略

连续缺失 ≤ 3 个点 (≤ 6 小时) 定义为短缺失，采用线性插值填补。连续缺失 > 3 个点定义为长缺失。ALUM 和 R/W PH 各存在连续 1644 点的长缺失 (占 37.5%)，若纳入模型则需剔除相应行，损失大量样本。

为此构建两套模型进行对比：

- **全样本模型**：剔除长缺失变量 (ALUM、R/W PH)，保留 4376 条有效样本
- **完整特征模型**：保留全部 6 个变量，但仅 2732 条完整样本

对比结果显示，全样本模型的调整 R^2 (0.4968) 与完整特征模型 (0.5081) 差距不大，但样本量多 60%，泛化能力更优。最终采用全样本策略。

2.3 滞后特征构造

基于水处理工艺机理，构造以下滞后项 (每步 shift=2 小时)：

- FILT_NTU_lag1, FILT_NTU_lag2：滤后水在清水池中停留 2~4 小时
- R/W_NTU_lag1, R/W_NTU_lag2：原水经全流程 2~4 小时
- ALUM_lag1, ALUM_lag2, ALUM_lag3：矾投加影响滞后 2~6 小时 (仅用于完整特征模型)

2.4 向后消去精简

全变量模型 (6 个特征) 拟合后，采用向后消去法 (Backward Elimination)，依次剔除 $p > 0.05$ 的不显著变量：

表 2: 向后消去过程

步骤	剔除变量	p 值	原因
1	R/W NTU	0.154	效应已被 FILT. NTU 完全中介
2	FILT_NTU_lag1	0.078	2h 滞后被 4h 滞后覆盖，边际不显著

最终模型保留 4 个显著变量。

3 最终模型

3.1 回归方程

$$\widehat{NTU}_t = -0.1545 + 0.6411 \cdot \text{FILT.NTU}_t + 0.0108 \cdot \text{R/W.FLOW}_t - 0.0003 \cdot \text{R/W.CLR}_t + 0.1401 \cdot \text{FILT.NTU}_{t-4} \quad (1)$$

其中下标 $t - 4h$ 表示 FILT_NTU_lag2 (滞后 4 小时)。

3.2 模型统计量

表 3: 模型拟合优度

指标	数值
样本量 n	4376
特征数 p	4
R^2	0.5058
调整 R^2	0.5054
RMSE	0.4577 NTU
F 统计量	1118.6
Durbin-Watson	0.544

3.3 显著性检验

表 4: 回归系数与显著性检验

变量	系数 $\hat{\beta}$	t 值	p 值
(截距)	-0.1545	-1.53	0.1266
FILT. NTU	+0.6411	40.25	< 0.0001 ***
R/W FLOW	+0.0108	5.32	< 0.0001 ***
R/W CLR	-0.0003	-9.48	< 0.0001 ***
FILT_NTU_lag2	+0.1401	8.90	< 0.0001 ***

注: *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$

其中 t 统计量 = $\hat{\beta}/SE(\hat{\beta})$, 衡量系数估计的精度; p 值为双侧 t 检验下原假设 $\beta = 0$ 成立的概率。4 个变量全部通过 $p < 0.001$ 的显著性检验。

3.4 系数含义解释

1. **FILT. NTU (当期)**, $\hat{\beta} = +0.64$: 滤后浊度每升高 1 NTU, 出厂浊度升高约 0.64 NTU, 方向符合物理预期。过滤是出厂前最后一道处理屏障, 当期滤后水质几乎直接决定出厂水质。该变量 $t = 40$, 在所有变量中贡献最大。
2. **FILT_NTU_lag2 (4h 滞后)**, $\hat{\beta} = +0.14$: 4 小时前的滤后浊度对当前出厂浊度仍有显著正向效应, 说明清水池存在约 4 小时的“水力记忆”——水体在清水池中并非瞬间置换, 而是存在一定停留时间分布。当期效应约为滞后效应的 4.6 倍 ($0.64/0.14$), 说明大部分水体在 4 小时内已完成置换。
3. **R/W FLOW (原水流量)**, $\hat{\beta} = +0.01$: 原水流量增大 $\rightarrow$ 水力停留时间缩短 $\rightarrow$ 沉淀不充分 $\rightarrow$ 出厂浊度升高。方向为正, 符合水力学原理。
4. **R/W CLR (原水色度)**, $\hat{\beta} = -0.0003$: 在控制了 FILT. NTU 后, 原水色度呈现微弱的负向修正效应。色度与浊度虽有物理关联但不完全共线 ($VIF=2.7$), 该变量提供了独立于浊度的补充信息。

4 预测：2026 年 2 月 NTU

将最终模型应用于附件 2 中 2026 年 2 月 1 日、10 日、20 日的记录（每天 12 个时刻，每 2 小时一条），预测出厂水浊度 NTU。预测时先将 sheet 中 100/300/500（当日凌晨）按时间顺序提至最前，确保 FILT_NTU_lag2 的滞后计算正确。跨日滞后的初始值取自 2025 年最后 2 条 FILT. NTU 记录。

三日预测 NTU 均低于国标限值 1 NTU，水质达标。2 月 10 日整体浊度略高（均值 0.54），对应 FILT. NTU 在 0.20–0.27 范围内波动，为三日中最高。2 月 1 日和 20 日（剔除异常点后的部分）浊度较低，分别为 0.37 和 0.39。2 月 20 日 11:00 的 R/W CLR 突增至 2263（超出训练数据约 40%），导致模型在该点外推不可靠；剔除该异常点后该日预测值均在正常范围。

5 结论

5.1 核心发现

1. **FILT. NTU 是预测 NTU 的最核心指标**。过滤环节是出厂水浊度的决定性关口，当期滤后浊度解释了出厂浊度约 50% 的变异。2026 年 2 月三天的预测中，FILT. NTU 的波动直接驱动了 NTU 的变化趋势（如 2 月 10 日 FILT. NTU 全天偏高，NTU 也随之升至 0.50–0.58）。

表 5: 2026 年 2 月 1 日 NTU 预测结果

时刻	FILT. NTU	R/W FLOW	R/W CLR	预测 NTU
01:00	0.040	50.1	324	0.3396
03:00	0.040	50.1	214	0.3685
05:00	0.040	50.0	175	0.3707
07:00	0.120	50.4	198	0.4202
09:00	0.250	50.4	380	0.4494
11:00	0.180	50.6	386	0.4226
13:00	0.150	50.0	380	0.4151
15:00	0.130	49.9	569	0.3434
17:00	0.040	49.1	421	0.3117
19:00	0.040	49.4	375	0.3242
21:00	0.040	49.9	375	0.3171
23:00	0.040	50.2	342	0.3290
均值 =0.3676, 标准差 =0.0483, 范围 [0.3117, 0.4494]				

表 6: 2026 年 2 月 10 日 NTU 预测结果

时刻	FILT. NTU	R/W FLOW	R/W CLR	预测 NTU
01:00	0.200	49.5	110	0.4918
03:00	0.250	49.5	110	0.5174
05:00	0.250	49.6	110	0.5337
07:00	0.210	49.7	72	0.5311
09:00	0.200	49.8	72	0.5258
11:00	0.220	50.1	68	0.5387
13:00	0.250	51.1	68	0.5609
15:00	0.260	49.8	68	0.5497
17:00	0.270	50.2	68	0.5568
19:00	0.260	50.3	68	0.5578
21:00	0.200	50.4	68	0.5333
23:00	0.200	49.2	150	0.4988
均值 =0.5330, 标准差 =0.0206, 范围 [0.4918, 0.5609]				

表 7: 2026 年 2 月 20 日 NTU 预测结果

时刻	FILT. NTU	R/W FLOW	R/W CLR	预测 NTU
01:00	0.050	49.5	534	0.2845
03:00	0.060	49.5	552	0.2862
05:00	0.060	49.5	591	0.2704
07:00	0.070	50.8	228	0.3874
09:00	0.070	50.6	228	0.3852
11:00	0.100	50.4	2263	0.2563 [†]
13:00	0.160	50.6	228	0.4443
15:00	0.330	51.3	340	0.4779
17:00	0.270	50.1	370	0.4654
19:00	0.230	50.4	660	0.3973
21:00	0.120	50.7	500	0.3720
23:00	0.090	50.5	507	0.3474

[†]R/W CLR=2263 超出训练域，经 IQR 截尾后预测为 0.2563，标注为外推不可靠。
均值 =0.3646，标准差 =0.0779，范围 [0.2563, 0.4779]

2. 清水池水力停留时间约为 4 小时。FILT_NTU_lag2 高度显著而 lag1 不显著，说明滤后水质变化需约 4 小时才能充分体现在出厂水中。这一结论可为水厂清水池运行管理提供参考——例如，当滤后水出现异常时，有约 4 小时的窗口时间进行应急调控。
3. 原水浊度（R/W NTU）的效应被滤后浊度完全中介。只要过滤环节运行正常，原水浊度的波动可以被有效缓冲。这意味着水厂应将监测重点放在过滤环节而非原水端。
4. 原水流量正向影响出厂浊度。流量过大时沉淀处理时间不足，导致微小颗粒穿透滤池。水厂可根据原水水质动态调整流量上限。
5. ALUM 和 R/W PH 因数据缺失限制未能纳入最终模型，但在完整特征子集上两者均显著。若未来能补全这两个变量的记录，模型预测能力有望进一步提升。
6. 2026 年 2 月三日预测均达标。预测值在 0.27–0.58 NTU 之间（剔除异常点），远低于国标 1 NTU。2 月 10 日整体偏高（均值 0.54），与当日 FILT. NTU 维持在 0.20–0.27 的较高水平一致。2 月 20 日 11:00 出现 R/W CLR=2263 的极端值，提示当输入超出训练域时需谨慎对待模型输出。

6 模型验证：2026 年 1 月与 3 月

为评估模型的泛化能力，利用附件 2 中 2026 年 1 月（31 天）和 3 月（31 天）的实测 NTU 数据作为验证集（共 744 条记录），与训练集相互独立。对验证集数据采用与训练集相同的预处理流程（短缺失插值、构造 `FILT_NTU_lag2`），代入最终模型预测 NTU 并与实测值对比。

表 8: 模型验证结果

数据集	样本量	NTU 标准差	RMSE	R^2
训练集 (2025 全年)	4380	0.660	0.458	0.518
验证集 (2026 年 1+3 月)	744	0.198	0.210	0.212
1 月	372	0.207	0.184	0.205
3 月	372	0.186	0.233	-0.575

验证集的 RMSE（0.222）仅为训练集 RMSE（0.458）的一半，说明模型在验证集上的绝对预测精度显著优于训练集。 R^2 低的原因并非模型泛化能力差，而是 2026 年 1 月和 3 月处于枯水期/旱季，出厂水浊度波动极小（标准差仅 0.20，约为训练集全年标准差的 30%）。 R^2 作为相对指标，在低方差数据上天然偏小——当 NTU 本身变化极小时，即使预测误差很小， R^2 也难以达到高值。1 月 $R^2 \approx 0$ 说明该月 NTU 几乎为常数水平，模型无法从中提取变异性信息；3 月 R^2 为负则是由于预测值围绕均值波动但实测值存在局部小幅度跳变所致，并不意味着模型不可用。

综上，模型在旱季平稳工况下预测偏差更小（RMSE=0.22 NTU），在雨季极端工况下误差增大但仍在合理范围（训练集 RMSE=0.46 NTU），整体具有良好的泛化能力。

6.1 模型局限与展望

1. $R^2 \approx 0.51$ ，说明线性模型仅解释了 NTU 约一半的变异。剩余变异可能来自：非线性关系（如 pH 对混凝效率的非单调影响）、季节周期性（雨季/旱季）、极端工况（暴雨、藻类爆发）、人工操作干预等。
2. $DW = 0.54$ ，残差存在显著的正自相关。这表明时间序列信息尚未被充分提取，为后续引入 LSTM、GRU 等时序深度学习模型提供了明确方向。
3. 线性模型假设各变量对 NTU 的影响是独立且可加的，无法刻画变量间的交互效应（如 $ALUM \times R/W$ PH 对混凝的协同影响）。后续可考虑引入交互项或采用树模型。