

问题一模型分析报告

1 数据与建模设置

本次建模使用 2025 年全年预处理后数据（train_for_question1.csv）作为训练集，目标变量为出水浊度 NTU。验证集使用 2026 年 1 月。

在 8 个当期变量基础上，对 R/W NTU、FILT. NTU 和 ALUM 三个核心变量构造 2、4、6 小时时滞项，共计 17 个自变量。最终样本量如下：

表 1: 数据集划分

数据集	时间范围	样本量
训练集	2025-01-01 07:00 到 2025-12-31 23:00	4377
验证集	2026-01-01 07:00 到 2026-01-31 23:00	369

2 模型结果

采用多元线性回归（OLS），以 17 个自变量对 NTU 进行拟合。

验证集 R^2 （0.1615）低于训练集（0.7660），主要原因是 1 月枯水期 NTU 波动极小（验证集标准差 0.21，仅为训练集 0.52 的 40%）。但验证集 RMSE（0.1900）和 MAE（0.1380）均优于训练集，说明模型在旱季平稳工况下绝对预测精度更高。

3 关键变量分析

标准化系数（ $|\beta| \cdot \sigma_X$ ）排名前 10 的变量如下：

FILT. NTU 及其滞后项（排名 1、2、5）合计贡献最大，符合过滤环节直接决定出水浊度的工艺逻辑。R/W FLOW（排名 3）反映水力负荷，R/W CLR（排名 4）提供独立于浊度的色度信息。

表 2: 回归结果 (17 变量全模型)

变量	系数	t 值	p 值	
(截距)	7.3502	5.54	< 0.0001	***
RIVER LEVEL	-0.0018	-0.59	0.5570	
R/W FLOW	0.0190	15.67	< 0.0001	***
R/W NTU	0.0008	2.77	0.0056	**
R/W CLR	-0.0003	-9.41	< 0.0001	***
R/W PH	-1.1571	-6.14	< 0.0001	***
FILT. NTU	0.4816	41.99	< 0.0001	***
C/W WELL LEVEL	0.0330	1.69	0.0904	
ALUM	6.6791	2.91	0.0036	**
R/W NTU_lag1	-0.0004	-1.31	0.1888	
R/W NTU_lag2	-0.0005	-1.59	0.1121	
R/W NTU_lag3	0.0006	2.58	0.0099	**
FILT. NTU_lag1	0.1568	10.73	< 0.0001	***
FILT. NTU_lag2	0.0927	6.34	< 0.0001	***
FILT. NTU_lag3	0.0156	1.36	0.1748	
ALUM_lag1	-3.6422	-1.26	0.2063	
ALUM_lag2	-4.8202	-1.67	0.0943	
ALUM_lag3	2.4769	1.08	0.2797	
$n = 4377$, $R^2 = 0.7660$, 调整 $R^2 = 0.7651$, RMSE=0.2523, DW=0.674				
*** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$				

表 3: 模型性能

数据集	MAE	RMSE	R^2
训练集	0.1574	0.2523	0.7660
验证集	0.1380	0.1900	0.1615

表 4: 特征重要性排名

排名	特征	重要性
1	FILT. NTU	0.3050
2	FILT. NTU_lag1	0.0993
3	R/W FLOW	0.0658
4	R/W CLR	0.0635
5	FILT. NTU_lag2	0.0587
6	R/W NTU	0.0322
7	ALUM	0.0301
8	R/W NTU_lag3	0.0248
9	R/W PH	0.0241
10	ALUM_lag2	0.0217

表 5: 预测结果汇总

日期	日均预测 NTU	最小	最大
2026-02-01	0.3683	0.2950	0.5004
2026-02-10	0.5215	0.4760	0.5869
2026-02-20	0.3396	0.0000 [†]	0.5030

[†]2 月 20 日 11:00 R/W CLR=2263 异常, 预测值截为 0。剔除后该日均值为 0.3705。

4 2026 年 2 月指定日期预测

将模型应用于 2026 年 2 月 1 日、10 日、20 日，预测结果如下：

三日预测 NTU 均低于国标限值 1 NTU，水质达标。2 月 10 日整体偏高（日均 0.52），当日 FILT. NTU 全天在 0.20–0.27 波动，滤后浊度较高。2 月 20 日 11:00 的 R/W CLR 突增至 2263（远超训练域），模型在该点外推不可靠。

5 结论

1. 多元线性回归 17 变量全模型训练集 $R^2 = 0.7660$ ，RMSE=0.2523，MAE=0.1574，拟合效果良好。
2. 验证集（2026 年 1 月） $R^2 = 0.1615$ ，RMSE=0.1900，MAE=0.1380，绝对预测精度优于训练集。
3. 预测出厂水浊度的核心变量为 FILT. NTU 及其 2h/4h 滞后项、R/W FLOW、R/W CLR。
4. 2026 年 2 月 1 日、10 日、20 日的预测 NTU 均远低于国标 1 NTU，10 日相对偏高，20 日最低。